实验 4 报告

一、实验过程

（一）第一题

分别编写 MapReduce 程序和 Spark 程序统计双十一最热门的商品和最受年轻人(age<30)关注的商家（“添加购物车+购买+添加收藏夹”前 100 名）

1. MapReduce

（1）最热门的商品

代码：

mr1/lab4_mr_1

运行命令：

先将输入文件放入 hdfs://user/<username>/input 文件夹下，再运行 hadoop jar task1-1.jar

输出：

mr1/output_mr1_2

```
1: 631714,      6205
2: 67897,       5850
3: 15207,       4490
4: 783997,      4316
5: 1059899,     3684
6: 186456,      3678
7: 191499,      3502
8: 822352,      3499
9: 454937,      3351
10: 441588,     3285
11: 159310,     3173
12: 353560,     3125
13: 655904,     2978
14: 764906,     2732
15: 195714,     2606
16: 668220,     2600
17: 1073970,    2541
18: 649596,     2493
19: 951042,     2489
20: 489523,     2474
21: 1039919,    2446
```

思路：

该题较为简单，之前作业出现过。分成两个 mapreduce 过程，第一个阶段统计商品出现的次数，输出一个词频统计的文件 output_mr1_1，第二个阶段对该输出进行排序，输出结果 output_mr1_2。

（2）最受年轻人(age<30)关注的商家

代码：

mr2/lab4_mr_2

运行命令：

先将输入文件放入 hdfs://user/<username>/input 文件夹下，再运行 hadoop jar task1-2.jar

输出：

mr2/output_mr2_3

```
1: 4044,        26050
2: 1102,        21416
3: 3760,        19265
4: 3828,        18963
5: 3698,        17976
6: 4173,        17490
7: 1393,        16234
8: 3491,        14430
9: 4976,        11845
10: 606,        11387
11: 173,        8889
12: 3677,       8478
13: 2385,       8261
14: 798,        7771
15: 1257,       7479
16: 184,        7124
17: 4538,       6996
18: 4752,       6930
19: 4282,       6852
20: 1480,       6808
21: 1663,       6681
22: 3734,       6677
23: 4798,       6568
24: 4160,       6498
25: 141,        6460
26: 1043,       6272
27: 4760,       6211
28: 4945,       5978
29: 2206,       5948
```

思路：

分为三个 mapreduce。

第一个阶段合并 user_log 和 user_info，Mapper 从文件名判断输入的来源，并根据来源在 value 前加 # 或 $ 来区分，发送给 Reducer

```java
protected void map(LongWritable key, Text value, Context context) throws IOException, InterruptedException {
    FileSplit fileSplit = (FileSplit) context.getInputSplit();
    String name = fileSplit.getPath().getName();

    String line = value.toString();
    if (line == null || line.equals(""))
        return;

    String[] split = line.split(",", -1);

    if (name.contains("user_log")) {
        String user = split[0];
        String item = split[1];
        String cat = split[2];
        String seller = split[3];
        String brand = split[4];
        String time = split[5];
        String action = split[6];
        context.write(new Text(user),
                new Text("#" + item + "," + cat + "," + seller + "," + brand + "," + time + "," + action));
    } else if (name.contains("user_info")) {
        String user = split[0];
        String age = split[1];
        String gender = split[2];
        context.write(new Text(user), new Text("$" + age + "," + gender));
    }
}
```

Reducer 再根据 value 前的标记，将记录分别放在两个 List 中，然后循环两个 List 将记录拼接在一起

```java
protected void reduce(Text key, Iterable<Text> values, Context context)
        throws IOException, InterruptedException {
    List<String> list1 = new LinkedList<>();
    List<String> list2 = new LinkedList<>();

    for (Text text : values) {
        String value = text.toString();
        if (value.startsWith("#")) {
            value = value.substring(1);
            list1.add(value);

        } else if (value.startsWith("$")) {
            value = value.substring(1);
            list2.add(value);
        }
    }

    for (String a : list1) {
        for (String b : list2) {
            context.write(key, new Text(a + "," + b));
        }
    }
}
```

后面两个阶段和上一题相似，中间过程输出在 output_mr2_1、output_mr2_2 中，最终输出为 output_mr2_3

2. Spark

（1）最热门的商品

代码：

sp1/lab4_sp_1

运行命令：

spark-submit --class “TopCommodity” topcommodity_2.12-1.0.jar hdfs://localhost:9000/user/lzt/input/user_log_format1.csv

输出：

sp1/output_sp1

```
(1,631714: 6205)
(2,67897: 5850)
(3,15207: 4490)
(4,783997: 4316)
(5,1059899: 3684)
(6,186456: 3678)
(7,191499: 3502)
(8,822352: 3499)
(9,454937: 3351)
(10,441588: 3285)
(11,159310: 3173)
(12,353560: 3125)
(13,655904: 2978)
(14,764906: 2732)
(15,195714: 2606)
(16,668220: 2600)
(17,1073970: 2541)
(18,649596: 2493)
(19,951042: 2489)
(20,489523: 2474)
(21,1039919: 2446)
(22,514725: 2357)
(23,81550: 2350)
(24,209821: 2276)
(25,221663: 2260)
(26,678194: 2251)
(27,843827: 2232)
```

思路：

和 MapReduce 一样，而且用 scala 的匿名函数可以让代码简单很多。代码长度跟 Mapreduce 一个 Mapper 的长度差不多。

```scala
object TopCommodity {
    def main(args: Array[String]) {
      if (args.length < 1) {
        System.err.println("Usage: <file>")
        System.exit(1)
      }

      val conf = new SparkConf().setAppName("Scala_TopCommodity")
      val sc = new SparkContext(conf)
      val file = sc.textFile(args(0))
      val file_sorted = file.map(line => line.split(",", -1))
                            .filter(line => line(6) != "0" && line(6) != "")
                            .map(line => (line(1), 1))
                            .reduceByKey(_ + _)
                            .sortBy(-_._2)
      val result = file_sorted.zipWithIndex()
                              .map(line => (line._1, line._2 + 1))
                              .map(line => (line._2, line._1._1 + ": " + String.valueOf(line._1._2)))
                              .take(100)

      val rdd_res = sc.parallelize(result, 1)
      rdd_res.saveAsTextFile("output_sp1")

      sc.stop()
    }
}
```

（2）最受年轻人(age<30)关注的商家

代码：

sp2/lab4_sp_2

运行命令：

spark-submit --class “TopSeller” topseller_2.12-1.0.jar
hdfs://localhost:9000/user/lzt/input/user_log_format1.csv
hdfs://localhost:9000/user/lzt/input/user_info_format1.csv

输出：

sp2/output_sp2_

```
(1,4044: 26050)
(2,1102: 21416)
(3,3760: 19265)
(4,3828: 18963)
(5,3698: 17976)
(6,4173: 17490)
(7,1393: 16234)
(8,3491: 14430)
(9,4976: 11845)
(10,606: 11387)
(11,173: 8889)
(12,3677: 8478)
(13,2385: 8261)
(14,798: 7771)
(15,1257: 7479)
(16,184: 7124)
(17,4538: 6996)
(18,4752: 6930)
(19,4282: 6852)
(20,1480: 6808)
(21,1663: 6681)
(22,3734: 6677)
(23,4798: 6568)
(24,4160: 6498)
(25,141: 6460)
(26,1043: 6272)
(27,4760: 6211)
(28,4945: 5978)
(29,2206: 5948)
```

思路：

思路也和 MapReduce 一样。之前的难点在于合并两个表，而 Scala 的 join 函数可以简单地做到这一点。

```
val file1_pair = file1.map(line => (line.split(",", -1)(0), line.split(",", -1)(3), line.split(",", -1)(6)))
                      .filter(line => line._3 != "0")
                      .map(line => (line._1, line._2))
val file2_pair = file2.map(line => (line.split(",", -1)(0), line.split(",", -1)(1)))
val file_join = file1_pair.join(file2_pair)
```

（二）第二题

编写 Spark 程序统计双十一购买了商品的男女比例，以及购买了商品的买家年龄段的比例

1. 男女比例

代码：

sp3/lab4_sp_3

运行命令：

spark-submit --class “MF_Proportion” mf_proportion_2.12-1.0.jar
hdfs://localhost:9000/user/lzt/input/user_log_format1.csv
hdfs://localhost:9000/user/lzt/input/user_info_format1.csv

输出：

在终端输出结果

```
**********输出结果**********
男性占总人数比例：0.2987
女性占总人数比例：0.7013
**********输出结果**********
```

思路：

先用 map 将两个表的 Rdd 转化为 pairRdd，筛选出购买的记录，再去掉重复的记录（在第一题我认为重复的购买和加购可以表明热门程度，而这一题统计男女比例就需要去重了）。

```
val file1 = sc.textFile(args(0))
            .map(line => (line.split(",", -1)(0), line.split(",", -1)(6)))
            .filter(line => line._2 == "2")
            .distinct()

val file2 = sc.textFile(args(1))
            .map(line => (line.split(",", -1)(0), line.split(",", -1)(2)))
            .filter(line => line._2 == "0" || line._2 == "1")
            .distinct()
```

然后合并两表，使用 countByValue 可以简单得出数量，除以总数得到比例。

```
val file_join = file1.join(file2)
                .flatMap(line => line._2._2)
                .countByValue()

var sum = 0.0
for (value <- file_join.values) {
  sum = sum + value
}

println("**********输出结果**********")
print("男性占总人数比例：")
println((file_join('1') / sum).formatted("%.4f"))
print("女性占总人数比例：")
println((file_join('0') / sum).formatted("%.4f"))
println("**********输出结果**********")
```

2. 年龄段比例

代码：

sp4/lab4_sp_4

运行命令：

spark-submit --class “Age_Proportion” age_proportion_2.12-1.0.jar hdfs://localhost:9000/user/lzt/input/user_log_format1.csv hdfs://localhost:9000/user/lzt/input/user_info_format1.csv

输出：

在终端输出结果

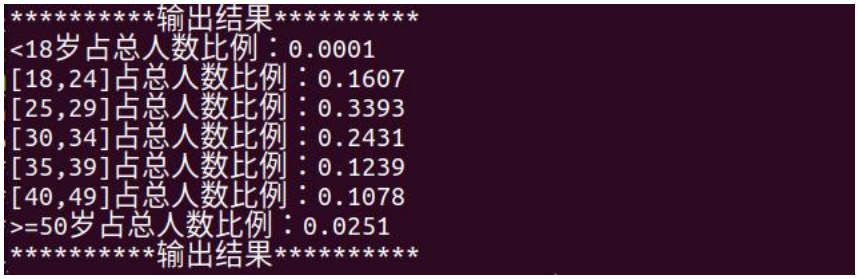

思路：

与男女比例类似，不再赘述。

（三）第三题

基于 Hive 或者 Spark SQL 查询双十一购买了商品的男女比例，以及购买了商品的买家年龄段的比例

1. 男女比例

代码：

sql1/lab4_sql_1

运行命令：

spark-submit --class “SparkSQL_MF_Proportion” sparksql_mf_proportion_2.12-1.0.jar hdfs://localhost:9000/user/lzt/input/user_log_format1.csv hdfs://localhost:9000/user/lzt/input/user_info_format1.csv

输出：

在终端输出结果

思路：

我没有在 spark-shell 中完成，是写在程序里的。需要注意的就是在用 SQL 语言操作数据时，需要先将数据集用 createOrReplaceTempView 创建视图。实现的思路和上面是一致的，都是筛选、去重、计算。

```scala
val info = spark.read.format("csv").option("header", "true")
                .load(args(1))

val log = spark.read.format("csv").option("header", "true")
                .load(args(0))

log.createOrReplaceTempView("df1")
var df1 = spark.sql("SELECT user_id,action_type FROM df1 WHERE action_type = 2")

df1.createOrReplaceTempView("df1")
df1 = spark.sql("SELECT DISTINCT user_id,action_type FROM df1")

info.createOrReplaceTempView("df2")
var df2 = spark.sql("SELECT user_id,gender FROM df2 WHERE gender = 0 or gender = 1")

df2.createOrReplaceTempView("df2")
df2 = spark.sql("SELECT DISTINCT user_id,gender FROM df2")

df1.createOrReplaceTempView("df1")
df2.createOrReplaceTempView("df2")
var df_join = spark.sql("SELECT * FROM df1 INNER JOIN df2 on df1.user_id=df2.user_id")

df_join.createOrReplaceTempView("df1")
var res = spark.sql("SELECT df1.gender, round(Count(*)/(SELECT count(df1.gender) AS count FROM df1), 4) AS Proportion FROM df1 GROUP
res.show()
```

2. 年龄段比例

代码：

sql2/lab4_sql_2

运行命令：

spark-submit --class “SparkSQL_Age_Proportion” sparksql_age_proportion_2.12-1.0.jar hdfs://localhost:9000/user/lzt/input/user_log_format1.csv hdfs://localhost:9000/user/lzt/input/user_info_format1.csv

输出：

```
+---------+----------+
|age_range|Proportion|
+---------+----------+
|        7|    0.0212|
|        3|    0.3393|
|        8|    0.0038|
|        5|    0.1239|
|        6|    0.1078|
|        1|    1.0E-4|
|        4|    0.2431|
|        2|    0.1607|
+---------+----------+
```

思路：

和上面是一样的，下面是主要程序

```scala
val info = spark.read.format("csv").option("header", "true")
                .load(args(1))

val log = spark.read.format("csv").option("header", "true")
                .load(args(0))

log.createOrReplaceTempView("df1")
var df1 = spark.sql("SELECT user_id,action_type FROM df1 WHERE action_type = 2")

df1.createOrReplaceTempView("df1")
df1 = spark.sql("SELECT DISTINCT user_id,action_type FROM df1")

info.createOrReplaceTempView("df2")
var df2 = spark.sql("SELECT user_id,age_range FROM df2 WHERE age_range = 1 or age_range = 2 or age_range = 3 or age_range = 4 or age_

df2.createOrReplaceTempView("df2")
df2 = spark.sql("SELECT DISTINCT user_id,age_range FROM df2")

df1.createOrReplaceTempView("df1")
df2.createOrReplaceTempView("df2")
var df_join = spark.sql("SELECT * FROM df1 INNER JOIN df2 on df1.user_id=df2.user_id")

df_join.createOrReplaceTempView("df1")
var res = spark.sql("SELECT df1.age_range, round(Count(*)/(SELECT count(df1.age_range) AS count FROM df1), 4) AS Proportion FROM df1
res.show()
```

（四）第四题

预测给定的商家中，哪些新消费者在未来会成为忠实客户，即需要预测这些新消费者在 6 个月内再次购买的概率。基于 Spark MLlib 编写程序预测回头客，评估实验结果的准确率。

说明：

该题我分为两部分完成。首先我使用 Spark MLlib 编写了一个简单的程序，因为在 spark 中对 dataframe 的操作不熟悉，花费了很长的时间，还是未能构建较复杂的特征，因此实现的结果得分很低。这也导致我本次实验提交时间很晚。

然后我直接用 python 对该题构造特征，用 lightGBM 进行预测，效果较好，在天池评测得分 0.6914395，29 名。

代码：（为了方便运行和调试，我使用 pyspark 和 jupyter notebook）

MLlib/MLlib.ipynb

竞赛/特征.ipynb，训练、预测.ipynb

输出：

MLlib/lr_res_df，svm_res_df

竞赛/submission_lgb.csv

思路：

在 MLlib 部分，我构造了 5 个特征：

①用户年龄、性别

```
# 添加年龄、性别
df_train = df_train.join(user_info, ["user_id"], "left")
df_train.limit(5).show()
```

```
+-------+-----------+-----+---------+------+
|user_id|merchant_id|label|age_range|gender|
+-------+-----------+-----+---------+------+
|  34176|       3906|    0|        6|     0|
|  34176|        121|    0|        6|     0|
|  34176|       4356|    1|        6|     0|
|  34176|       2217|    0|        6|     0|
| 230784|       4818|    0|        0|     0|
+-------+-----------+-----+---------+------+
```

②log_count 为某用户在某店加入购物车、购买、收藏的总数

```
# log_count为某用户在某店加入购物车、购买、收藏的总数
user_log_exceptClick = user_log[user_log["action_type"] != 0]
log_count = user_log_exceptClick.groupby(["user_id", "seller_id"]).count()
log_count = log_count.withColumnRenamed("seller_id", "merchant_id").withColumnRenamed("count", "log_count")
df_train = df_train.join(log_count, ["user_id", "merchant_id"],"left")
df_train.limit(5).show()
```

```
+-------+-----------+-----+---------+------+---------+
|user_id|merchant_id|label|age_range|gender|log_count|
+-------+-----------+-----+---------+------+---------+
|    464|       4718|    0|        6|     0|        1|
|    867|       3152|    0|        3|     0|        1|
|   1882|       4377|    0|        6|     1|        1|
|   2450|       2760|    0|        0|     0|        2|
|   2766|       3885|    0|        4|     1|        1|
+-------+-----------+-----+---------+------+---------+
```

③cart_count 为某用户在某店加入购物车的总数

```
# cart_count为某用户在某店加入购物车的总数
user_log_cart = user_log[user_log["action_type"] == 1]
cart_count = user_log_cart.groupby(["user_id", "seller_id"]).count()
cart_count = cart_count.withColumnRenamed("seller_id", "merchant_id").withColumnRenamed("count", "cart_count")
df_train = df_train.join(cart_count, ["user_id", "merchant_id"], "left")
df_train.limit(5).show()
```

```
+-------+-----------+-----+---------+------+---------+----------+
|user_id|merchant_id|label|age_range|gender|log_count|cart_count|
+-------+-----------+-----+---------+------+---------+----------+
|    464|       4718|    0|        6|     0|        1|      null|
|    867|       3152|    0|        3|     0|        1|      null|
|   1882|       4377|    0|        6|     1|        1|      null|
|   2450|       2760|    0|        0|     0|        2|      null|
|   2766|       3885|    0|        4|     1|        1|      null|
+-------+-----------+-----+---------+------+---------+----------+
```

④buy_count 为某用户在某店购买的总数

```
# buy_count为某用户在某店购买的总数
user_log_buy = user_log[user_log["action_type"] == 2]
buy_count = user_log_buy.groupby(["user_id", "seller_id"]).count()
buy_count = buy_count.withColumnRenamed("seller_id", "merchant_id").withColumnRenamed("count", "buy_count")
df_train = df_train.join(buy_count, ["user_id", "merchant_id"], "left")
df_train.limit(5).show()
```

```
+-------+-----------+-----+---------+------+---------+----------+---------+
|user_id|merchant_id|label|age_range|gender|log_count|cart_count|buy_count|
+-------+-----------+-----+---------+------+---------+----------+---------+
|    464|       4718|    0|        6|     0|        1|      null|        1|
|    867|       3152|    0|        3|     0|        1|      null|        1|
|   1882|       4377|    0|        6|     1|        1|      null|        1|
|   2450|       2760|    0|        0|     0|        2|      null|        2|
|   2766|       3885|    0|        4|     1|        1|      null|        1|
+-------+-----------+-----+---------+------+---------+----------+---------+
```

⑤collect_count 为某用户在某店收藏的总数

```
# collect_count为某用户在某店收藏的总数
user_log_collect = user_log[user_log["action_type"] == 3]
collect_count = user_log_collect.groupby(["user_id", "seller_id"]).count()
collect_count = collect_count.withColumnRenamed("seller_id", "merchant_id").withColumnRenamed("count", "collect_count")
df_train = df_train.join(collect_count, ["user_id", "merchant_id"], "left")
df_train.limit(5).show()
```

```
+-------+-----------+-----+---------+------+---------+----------+---------+-------------+
|user_id|merchant_id|label|age_range|gender|log_count|cart_count|buy_count|collect_count|
+-------+-----------+-----+---------+------+---------+----------+---------+-------------+
|    464|       4718|    0|        6|     0|        1|      null|        1|         null|
|    867|       3152|    0|        3|     0|        1|      null|        1|         null|
|   1882|       4377|    0|        6|     1|        1|      null|        1|         null|
|   2450|       2760|    0|        0|     0|        2|      null|        2|         null|
|   2766|       3885|    0|        4|     1|        1|      null|        1|         null|
+-------+-----------+-----+---------+------+---------+----------+---------+-------------+
```

得到特征数据后，我采用逻辑回归和支持向量机模型，代码参考官网和其他示例。

下面是逻辑回归的训练结果，测试误差 0.061263329029790085

```
# 逻辑回归，参考官方代码
# Run training algorithm to build the model
lr_model = LogisticRegressionWithLBFGS.train(training)

# Compute raw scores on the test set
predictionAndLabels1 = test.map(lambda lp: (float(lr_model.predict(lp.features)), lp.label))

# Instantiate metrics object
metrics = BinaryClassificationMetrics(predictionAndLabels1)

# Area under precision-recall curve
print("Area under PR = %s" % metrics.areaUnderPR)

# Area under ROC curve
print("Area under ROC = %s" % metrics.areaUnderROC)

# Evaluating the model on test data
test_error = predictionAndLabels1.filter(lambda lp: lp[0] != lp[1]).count() / float(test.count())
print("Test Error = " + str(test_error))
```

```
Area under PR = 0.09310795813683474
Area under ROC = 0.50004247074441
Test Error = 0.061263329029790085
```

SVM，测试误差为 0.061205948453115284

```
# SVM
# Build the model
from pyspark.mllib.classification import SVMWithSGD, SVMModel
svm_model = SVMWithSGD.train(training, iterations=100)

# Evaluating the model on test data
predictionAndLabels2 = test.map(lambda lp: (lp.label, svm_model.predict(lp.features)))
test_error = predictionAndLabels2.filter(lambda lp: lp[0] != lp[1]).count() / float(test.count())
print("Test Error = " + str(test_error))
```

```
Test Error = 0.061205948453115284
```

但是放到官网上评测分数都很低，一个是 0.5001877，还有一个是 0.5。这是由于我的特征选取太少，而且模型不够好。因为 spark 中的 dataframe 和 pandas 中的 dataframe 操作有很大的不同，很多特征我用 pyspark 都无法实现。

后来我直接用 pandas 处理数据，用 lightGBM 来预测，效果较好，得分为 0.6914395，下面说一下实现的思路。

我先是搜索相关的资料，搜到了一篇排名比较高的文章 https://zhuanlan.zhihu.com/p/137905297，作者 kagging 在天池的得分为 0.685928，排名 75。在看了他的思路之后，我先是构建了以下几个特征：

1. 用户特征

①点击、加购、购买、收藏总记录数：u1

②用户有操作记录的 item_id 的个数（去重后）：u2

③用户有操作记录的 cat_id 的个数（去重后）：u3

④用户有操作记录的 merchant_id 的个数（去重后）：u4

⑤用户有操作记录的 brand_id 的个数（去重后）：u5

⑥用户有操作记录的最近时间和最晚时间的间隔天数：u6

⑦点击、加购、购买、收藏分别记录数：u7、u8、u9、u10

```
# 点击、加购、购买、收藏总记录数：u1
temp = groups.size().reset_index().rename(columns={0:'u1'})
matrix = matrix.merge(temp, on='user_id', how='left')

# 用户有操作记录的item_id的个数（去重后）：u2
temp = groups['item_id'].agg([('u2', 'nunique')]).reset_index()
matrix = matrix.merge(temp, on='user_id', how='left')

# 用户有操作记录的cat_id的个数（去重后）：u3
temp = groups['cat_id'].agg([('u3', 'nunique')]).reset_index()
matrix = matrix.merge(temp, on='user_id', how='left')

# 用户有操作记录的merchant_id的个数（去重后）：u4
temp = groups['merchant_id'].agg([('u4', 'nunique')]).reset_index()
matrix = matrix.merge(temp, on='user_id', how='left')

# 用户有操作记录的brand_id的个数（去重后）：u5
temp = groups['brand_id'].agg([('u5', 'nunique')]).reset_index()
matrix = matrix.merge(temp, on='user_id', how='left')

# 用户有操作记录的最近时间和最晚时间的间隔天数：u6
temp = groups['time_stamp'].agg([('F_time', 'min'), ('L_time', 'max')]).reset_index()
temp['u6'] = (temp['L_time'] - temp['F_time']).dt.days
matrix = matrix.merge(temp[['user_id', 'u6']], on='user_id', how='left')

# 点击、加购、购买、收藏分别记录数：u7、u8、u9、u10
temp = groups['action_type'].value_counts().unstack().reset_index().rename(columns={0:'u7', 1:'u8', 2:'u9', 3:'u10'})
matrix = matrix.merge(temp, on='user_id', how='left')
```

2. 商店特征

①商店被点击、加购、购买、收藏总记录数：m1

②商店有操作记录的 user_id 的个数（去重后）：m2

③商店有操作记录的 item_id 的个数（去重后）：m3

④商店有操作记录的 cat_id 的个数（去重后）：m4

⑤商店有操作记录的 brand_id 的个数（去重后）：m5

⑥商店被点击、加购、购买、收藏各自的记录数：m6、m7、m8、m9

```
# 商店被点击、加购、购买、收藏总记录数：m1
temp = groups.size().reset_index().rename(columns={0:'m1'})
matrix = matrix.merge(temp, on='merchant_id', how='left')

# 商店有操作记录的user_id的个数（去重后）：m2
temp = groups['user_id'].agg([('m2', 'nunique')]).reset_index()
matrix = matrix.merge(temp, on='merchant_id', how='left')

# 商店有操作记录的item_id的个数（去重后）：m3
temp = groups['item_id'].agg([('m3', 'nunique')]).reset_index()
matrix = matrix.merge(temp, on='merchant_id', how='left')

# 商店有操作记录的cat_id的个数（去重后）：m4
temp = groups['cat_id'].agg([('m4', 'nunique')]).reset_index()
matrix = matrix.merge(temp, on='merchant_id', how='left')

# 商店有操作记录的brand_id的个数（去重后）：m5
temp = groups['brand_id'].agg([('u5', 'nunique')]).reset_index()
matrix = matrix.merge(temp, on='merchant_id', how='left')

# 商店被点击、加购、购买、收藏各自的记录数：m6、m7、m8、m9
temp = groups['action_type'].value_counts().unstack().reset_index().rename(columns={0:'m6', 1:'m7', 2:'m8', 3:'m9'})
matrix = matrix.merge(temp, on='merchant_id', how='left')
```

3. 用户-商店特征

①用户——商店点击、加购、购买、收藏总记录数：um1

②用户——商店有操作记录的 item_id 的个数（去重后）：um2

③用户——商店有操作记录的 cat_id 的个数（去重后）：um3

④用户——商店有操作记录的 brand_id 的个数（去重后）：um4

⑤用户——商店被点击、加购、购买、收藏各自的记录数：um5、um6、um7、um8

⑥用户——商店有操作记录的最近时间和最晚时间的间隔天数：um9

```
# 用户—商店点击、加购、购买、收藏总记录数：um1
temp = groups.size().reset_index().rename(columns={0:'um1'})
matrix = matrix.merge(temp, on=['user_id', 'merchant_id'], how='left')

# 用户—商店有操作记录的item_id的个数（去重后）：um2
temp = groups['item_id'].agg([('um2', 'nunique')]).reset_index()
matrix = matrix.merge(temp, on=['user_id', 'merchant_id'], how='left')

# 用户—商店有操作记录的cat_id的个数（去重后）：um3
temp = groups['cat_id'].agg([('um3', 'nunique')]).reset_index()
matrix = matrix.merge(temp, on=['user_id', 'merchant_id'], how='left')

# 用户—商店有操作记录的brand_id的个数（去重后）：um4
temp = groups['brand_id'].agg([('um4', 'nunique')]).reset_index()
matrix = matrix.merge(temp, on=['user_id', 'merchant_id'], how='left')

# 用户—商店被点击、加购、购买、收藏各自的记录数：um5、um6、um7、um8
temp = groups['action_type'].value_counts().unstack().reset_index().rename(columns={0:'um5',1:'um6',2:'um7',3:'um8'})
matrix = matrix.merge(temp, on=['user_id', 'merchant_id'], how='left')

# 用户—商店有操作记录的最近时间和最晚时间的间隔天数：um9
temp = groups['time_stamp'].agg([('frist', 'min'), ('last', 'max')]).reset_index()
temp['um9'] = (temp['last'] - temp['frist']).dt.days
temp.drop(['frist', 'last'], axis=1, inplace=True)
matrix = matrix.merge(temp, on=['user_id', 'merchant_id'], how='left')
```

训练后进行预测，在天池上得分大概只有 0.65，根本达不到作者说的 0.685928，我估计是作者出于私心，没有写一些重要的特征。

通过我的思考，又添加了如下若干个特征：（缺失值填 0，性别缺失填 2）

1. 用户特征：

①每个用户在 5-11 月内的购买数量

解释：用户的购买数量和他是否会复购有极大的关联，而且时间的不同也很重要，有理由认为，靠近 11 月的购买量越多，说明他的生活条件越好，或是购

物欲望越强烈，复购的可能性越大。

```
# 每个用户在5-11月内的购买数量
buy_11 = user_log_data[(user_log_data['month'] == "11") & (user_log_data['action_type'] == 2)]
buy_10 = user_log_data[(user_log_data['month'] == "10") & (user_log_data['action_type'] == 2)]
buy_9 = user_log_data[(user_log_data['month'] == "09") & (user_log_data['action_type'] == 2)]
buy_8 = user_log_data[(user_log_data['month'] == "08") & (user_log_data['action_type'] == 2)]
buy_7 = user_log_data[(user_log_data['month'] == "07") & (user_log_data['action_type'] == 2)]
buy_6 = user_log_data[(user_log_data['month'] == "06") & (user_log_data['action_type'] == 2)]
buy_5 = user_log_data[(user_log_data['month'] == "05") & (user_log_data['action_type'] == 2)]

user_buy_11 = buy_11.groupby('user_id', as_index=False)['month'].agg({'user_buy_11': 'count'}).fillna(0)
user_buy_10 = buy_10.groupby('user_id', as_index=False)['month'].agg({'user_buy_10': 'count'}).fillna(0)
user_buy_9 = buy_9.groupby('user_id', as_index=False)['month'].agg({'user_buy_9': 'count'}).fillna(0)
user_buy_8 = buy_8.groupby('user_id', as_index=False)['month'].agg({'user_buy_8': 'count'}).fillna(0)
user_buy_7 = buy_7.groupby('user_id', as_index=False)['month'].agg({'user_buy_7': 'count'}).fillna(0)
user_buy_6 = buy_6.groupby('user_id', as_index=False)['month'].agg({'user_buy_6': 'count'}).fillna(0)
user_buy_5 = buy_5.groupby('user_id', as_index=False)['month'].agg({'user_buy_5': 'count'}).fillna(0)

matrix = matrix.merge(user_buy_11, on=['user_id'], how='left')
matrix = matrix.merge(user_buy_10, on=['user_id'], how='left')
matrix = matrix.merge(user_buy_9, on=['user_id'], how='left')
matrix = matrix.merge(user_buy_8, on=['user_id'], how='left')
matrix = matrix.merge(user_buy_7, on=['user_id'], how='left')
matrix = matrix.merge(user_buy_6, on=['user_id'], how='left')
matrix = matrix.merge(user_buy_5, on=['user_id'], how='left')
```

②购买——点击比

解释：这说明用户的习惯，比值越大，越容易消费。

```
matrix['r1'] = matrix['u9']/matrix['u7'] # 用户购买点击比
```

2. 商店特征：

①每个商店在 5-11 月内的用户购买数量

解释：和上面类似，如果一家店最近的销量好，说明它的经营状况好，或是商品更有吸引力。

```
# 每个商店在5-11月内的购买数量
merchant_buy_11 = buy_11.groupby('merchant_id', as_index=False)['month'].agg({'merchant_buy_11': 'count'}).fillna(0)
merchant_buy_10 = buy_10.groupby('merchant_id', as_index=False)['month'].agg({'merchant_buy_10': 'count'}).fillna(0)
merchant_buy_9 = buy_9.groupby('merchant_id', as_index=False)['month'].agg({'merchant_buy_9': 'count'}).fillna(0)
merchant_buy_8 = buy_8.groupby('merchant_id', as_index=False)['month'].agg({'merchant_buy_8': 'count'}).fillna(0)
merchant_buy_7 = buy_7.groupby('merchant_id', as_index=False)['month'].agg({'merchant_buy_7': 'count'}).fillna(0)
merchant_buy_6 = buy_6.groupby('merchant_id', as_index=False)['month'].agg({'merchant_buy_6': 'count'}).fillna(0)
merchant_buy_5 = buy_5.groupby('merchant_id', as_index=False)['month'].agg({'merchant_buy_5': 'count'}).fillna(0)

matrix = matrix.merge(merchant_buy_11, on=['merchant_id'], how='left')
matrix = matrix.merge(merchant_buy_10, on=['merchant_id'], how='left')
matrix = matrix.merge(merchant_buy_9, on=['merchant_id'], how='left')
matrix = matrix.merge(merchant_buy_8, on=['merchant_id'], how='left')
matrix = matrix.merge(merchant_buy_7, on=['merchant_id'], how='left')
matrix = matrix.merge(merchant_buy_6, on=['merchant_id'], how='left')
matrix = matrix.merge(merchant_buy_5, on=['merchant_id'], how='left')
```

②每个商店的复购次数

解释：这一点很重要，如果一家店的复购次数大，说明这家店很容易吸引回头客。

```
# 每个商店的复购次数
temp = user_log_data[user_log_data['action_type'] == 2]
temp = temp.drop_duplicates(subset=['merchant_id', 'time_stamp', 'user_id'])
temp = temp.groupby('merchant_id').apply(lambda x: x['user_id'].count() - x['user_id'].nunique())
temp = temp.reset_index().rename(columns={0:'repeat_count'})
matrix = matrix.merge(temp, on='merchant_id', how='left')
```

③购买——点击比

解释：说明了商店的吸引力

```
matrix['r2'] = matrix['m8']/matrix['m6'] # 商家购买点击比
```

3. 用户——商店特征

①每个用户——商店在 5-11 月内的购买数量

解释：和上面类似。

```
# 每个用户—商店在5-11月内的购买数量
user_merchant_buy_11 = buy_11.groupby(['user_id','merchant_id'], as_index=False)['month'].agg({'user_merchant_buy_11': 'count'})
.fillna(0)
user_merchant_buy_10 = buy_10.groupby(['user_id','merchant_id'], as_index=False)['month'].agg({'user_merchant_buy_10': 'count'})
.fillna(0)
user_merchant_buy_9 = buy_9.groupby(['user_id','merchant_id'], as_index=False)['month'].agg({'user_merchant_buy_9': 'count'}).fillna
(0)
user_merchant_buy_8 = buy_8.groupby(['user_id','merchant_id'], as_index=False)['month'].agg({'user_merchant_buy_8': 'count'}).fillna
(0)
user_merchant_buy_7 = buy_7.groupby(['user_id','merchant_id'], as_index=False)['month'].agg({'user_merchant_buy_7': 'count'}).fillna
(0)
user_merchant_buy_6 = buy_6.groupby(['user_id','merchant_id'], as_index=False)['month'].agg({'user_merchant_buy_6': 'count'}).fillna
(0)
user_merchant_buy_5 = buy_5.groupby(['user_id','merchant_id'], as_index=False)['month'].agg({'user_merchant_buy_5': 'count'}).fillna
(0)

matrix = matrix.merge(user_merchant_buy_11, on=['user_id','merchant_id'], how='left')
matrix = matrix.merge(user_merchant_buy_10, on=['user_id','merchant_id'], how='left')
matrix = matrix.merge(user_merchant_buy_9, on=['user_id','merchant_id'], how='left')
matrix = matrix.merge(user_merchant_buy_8, on=['user_id','merchant_id'], how='left')
matrix = matrix.merge(user_merchant_buy_7, on=['user_id','merchant_id'], how='left')
matrix = matrix.merge(user_merchant_buy_6, on=['user_id','merchant_id'], how='left')
matrix = matrix.merge(user_merchant_buy_5, on=['user_id','merchant_id'], how='left')
```

②购买——点击比

解释：和上面类似。

```
matrix['r3'] = matrix['um7']/matrix['um5'] #不同用户不同商家购买点击比
```

得到特征数据后，保存在 train_data.csv，test_data.csv 中。然后读取 train_data.csv，将其分为训练集和测试集，使用 lightgbm 模型训练，最后预测 test_data.csv 中的概率，得到 submission_lgb.csv。（这里偷了点小懒，直接用了 Kagging 的参数，发现效果比他做得还好，就没有继续调参了）

```
    model_lgb = lgb.LGBMClassifier(
        max_depth=10,
        n_estimators=1000,
        min_child_weight=200,
        colsample_bytree=0.8,
        subsample=0.8,
        eta=0.3,
        seed=42
    )

    model_lgb.fit(
        X_train[i],
        y_train[i],
        eval_metric='auc',
        eval_set=[(X_train[i], y_train[i]), (X_valid[i], y_valid[i])],
        verbose=False,
        early_stopping_rounds=10

    )

    print(model_lgb.best_score_['valid_1']['auc'])

    pred = model_lgb.predict_proba(test_data)
    pred = pd.DataFrame(pred[:,1])
    pred_lgbms.append(pred)
```

二、环境配置

1. Spark 配置

Spark 的安装比较简单，解压后设置一下 spark-env.sh 和环境变量即可

spark-env.sh

```
export JAVA_HOME=/usr
export SCALA_HOME=/usr/local/scala
export SPARK_MASTER_IP=localhost
export SPARK_LOCAL_IP=localhost
export SPARK_WORKER_MEMORY=2g
export SPARK_CONF_DIR=/usr/local/hadoop/etc/hadoop
export LD_LIBRARY_PATH=/usr/local/hadoop/lib/native
export SPARK_DIST_CLASSPATH=$(/usr/local/hadoop/bin/hadoop classpath)
```

/etc/profile

```
export SCALA_HOME=/usr/local/scala
export SPARK_HOME=/usr/local/spark
```

```
export PATH=$PATH:$HBASE_HOME/bin:$M2_HOME/bin:$HADOOP_HOME/bin:$HADOOP_HOME/sbi
n:$SCALA_HOME/bin:$SPARK_HOME/bin:$HIVE_HOME/bin:$SPARK_HOME/python
```

启动 Hadoop 后，到 spark/sbin 目录内，运行./start-all.sh

```
lzt@lzt-virtual-machine:/usr/local/spark/sbin$ jps
4433 Jps
4385 Worker
4196 Master
3620 ResourceManager
3110 DataNode
2936 NameNode
3357 SecondaryNameNode
3790 NodeManager
```

打开 spark-shell

```
lzt@lzt-virtual-machine:~/Documents/Completed/sp1$ spark-shell
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLeve
l(newLevel).
Spark context Web UI available at http://localhost:4040
Spark context available as 'sc' (master = local[*], app id = local-1609124457434
).
Spark session available as 'spark'.
Welcome to
      ____              __
     / __/__  ___ _____/ /__
    _\ \/ _ \/ _ `/ __/  '_/
   /___/ .__/\_,_/_/ /_/\_\   version 3.0.1
      /_/

Using Scala version 2.12.10 (OpenJDK 64-Bit Server VM, Java 1.8.0_275)
Type in expressions to have them evaluated.
Type :help for more information.

scala>
```

三、问题总结

本次实验在配置环境上没有遇到太大的问题，主要是学习 spark 编程耗时间。（上次配好虚拟机确实一劳永逸）

1. spark 无法读取 hdfs 文件

解决方法：

编辑 spark-env.sh 文件(vim ./conf/spark-env.sh)，在第一行添加以下:

export SPARK_DIST_CLASSPATH=$(/usr/local/hadoop/bin/hadoop classpath)

有了上面的配置信息以后，Spark 就可以把数据存储到 Hadoop 分布式文件系统 HDFS 中，也可以从 HDFS 中读取数据。如果没有配置上面信息，Spark 就只能读写本地数据，无法读写 HDFS 数据。

2. sbt 使用国内镜像下载很慢

解决方法：

这个要用 aliyun 的源，huaweiyun 的还是很慢，不过我一开始的解决方法是让电脑开了一晚。

3. scala 分割遇到缺失值的处理

解决方法：

一开始我用一个数组存储，每次都要判断一下数组的大小来查看是否有缺失值，后来直接使用 split(“”，-1)，可以将缺失值留空，比如 1,2,,这个字符串，如果用 split(“”)只会读到 “1 2 ”两个值，用 split(“”，-1)会读到“ 1 2 空 空 ”四个值。